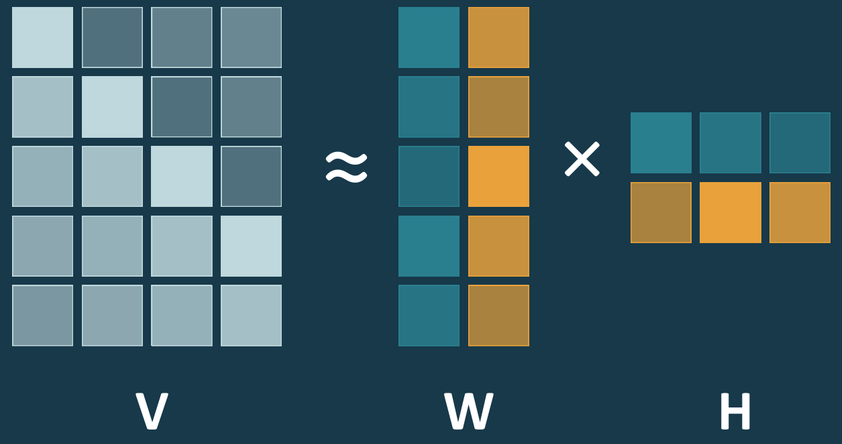
NMF và tóm tắt văn bản dựa trên chủ đề

Phân tích và khai phá dữ liệu văn bản

Nhóm 04



Thành viên nhóm

1. Đỗ Văn Tân
2. Hà Huy Khôi
3. Hoàng Minh Sơn
4. Đỗ Quốc Tấn

Bài toán: tóm tắt bằng cách chọn câu

Một bài báo (ví dụ minh họa)

(1) Thành phố A khai trương tuyến buýt điện nối trung tâm với sân bay.
(2) Tuyến dài khoảng 30 km, cứ 15 phút có một chuyến.
(3) Giá vé 45.000 đồng, miễn phí cho người cao tuổi.
(4) Nhiều hành khách khen xe êm và sạch.
(5) Thành phố dự kiến mở thêm 3 tuyến trong năm sau.

Câu được chọn vào bản tóm tắt

Trích xuất

Chọn câu có sẵn trong bài, giữ nguyên văn, nên không bịa số liệu.

Trừu tượng

Viết lại bằng lời mới: tự nhiên hơn nhưng dễ sai thông tin.

Câu quan trọng = câu thể hiện rõ các chủ đề chính

Từ LSA đến NMF: vì sao cấm số âm

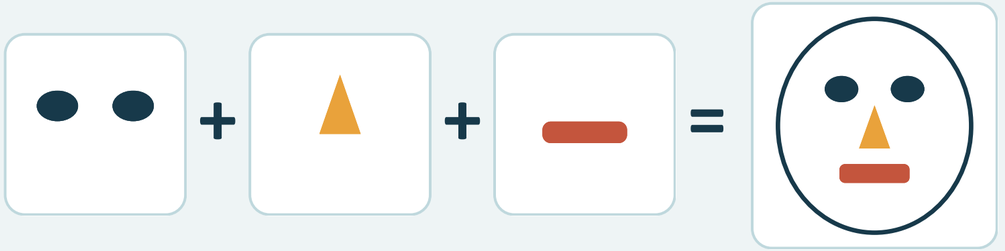
LSA dùng SVD

Từ	Một khái niệm
pin	+0.71
camera	**−0.71**
điện_thoại	0

?

Số âm: các khái niệm cộng – trừ bù nhau. Đúng về toán, nhưng khó đọc thành một "chủ đề" có thật.

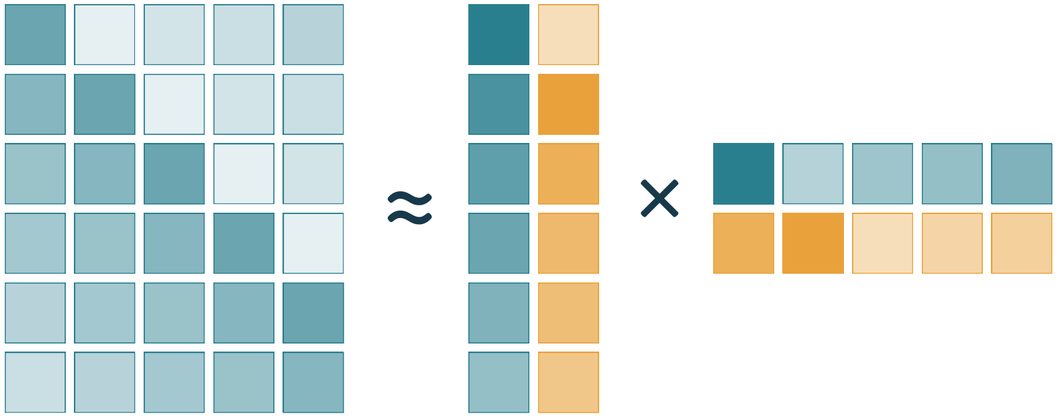
NMF: chỉ được cộng



Mỗi chủ đề là một "bộ phận" dùng chung; mỗi câu là một "công thức pha" các bộ phận

"Một câu không thể chứa −20% chủ đề."

NMF là gì? V ≈ W × H



V
từ × câu

W
từ × k
mỗi cột: một chủ đề (dùng chung)

H
k × câu
mỗi cột: câu pha các chủ đề (riêng)

Ở ví dụ của nhóm, chúng ta có 4 câu:

- Pin và camera của điện thoại.
- Camera của điện thoại.
- Phở và bún.
- Bún và phở.

W (5 từ × 2 chủ đề)

	CĐ 1	CĐ 2
pin	0.001	0.394
camera	0.000	0.429
điện_thoại	0.000	0.429
phở	0.334	0.000
bún	0.334	0.000

H (2 chủ đề × 4 câu)

	Câu 1	Câu 2	Câu 3	Câu 4
CĐ 1	0.004	0.002	1.037	1.037
CĐ 2	0.727	0.569	0.000	0.000

Thừa số hóa
Viết thành tích, như 12 = 3 × 4. Ở đây V ≈ W × H.

Không âm
Mọi phần tử của V, W, H đều ≥ 0.

k = số chủ đề
Siêu tham số, chọn trước

Mục tiêu và sai số

Mục tiêu

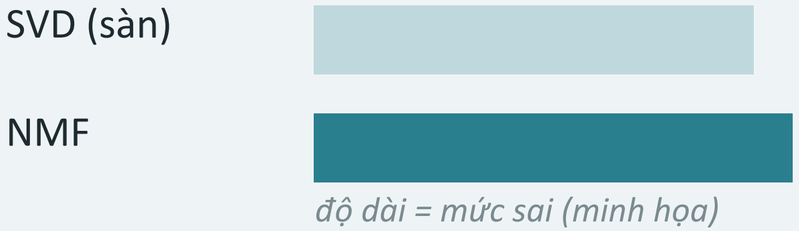
$$\min ||V - WH||^2$$

với $W \geq 0$, $H \geq 0$

Mức sai = tổng bình phương chênh lệch trên mọi ô.

Ví dụ: ô có V = 1, WH = 2 → $(1 - 2)^2 = 1$

"Sàn" SVD



Cùng k, NMF không thể sai ít hơn SVD: đó là cái giá của việc dễ đọc.

Chỉ số "V được giải thích" chỉ khoảng 25–32% là mức nén (ép cả bài vào vài chủ đề), không phải chất lượng tóm tắt. Điều đáng xem: NMF chỉ cách sàn SVD rất ít.

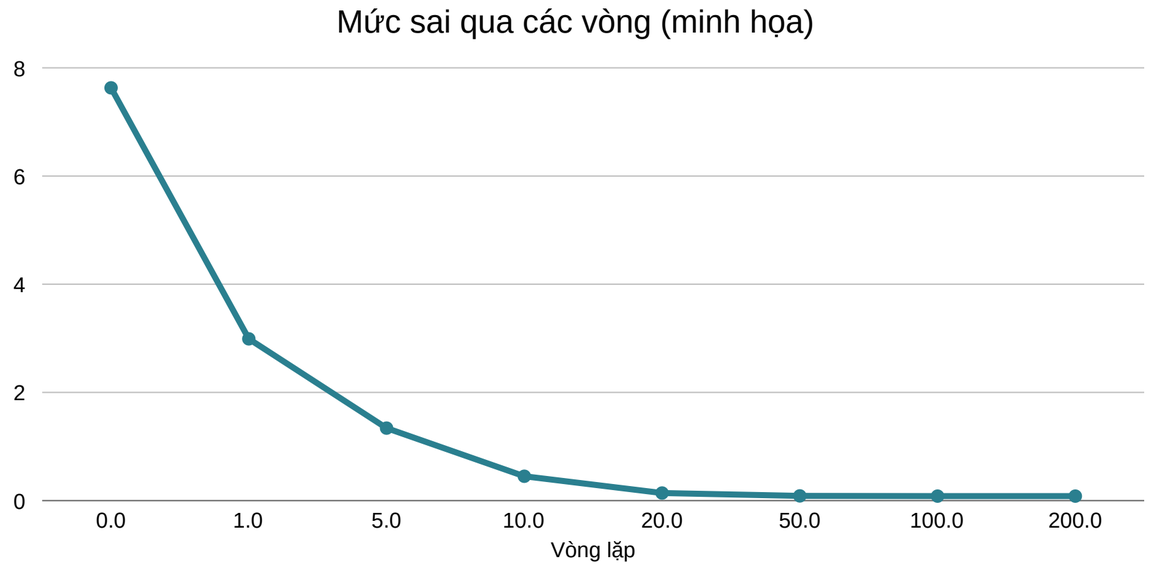
Máy "khớp" W, H thế nào

1. **Khởi tạo W, H ≥ 0**
   Chạy 5 lần với seed 0–4
2. **Cập nhật H, rồi W**
   Nhân với tỉ lệ (công thức bên phải)
3. **Tính sai số**
   $||V - WH||^2$ sau mỗi vòng
4. **Dừng khi sai số phẳng**
   tol, số vòng tối đa; giữ lần có sai số nhỏ nhất

Cập nhật nhân (Lee & Seung)

$$H \leftarrow H \times (WTV) / (WTWH)$$
$$W \leftarrow W \times (VHT) / (WHHT)$$

× và / tính theo từng phần tử · tỉ lệ < 1 thì giảm, > 1 thì tăng · luôn ≥ 0



Lắp ráp NMF vào hệ thống tóm tắt

1
Bài báo

Văn bản đầu vào

→

2
Tiền xử lý

Tách câu, tách từ, bỏ từ dừng

→

3
Ma trận V

TF-IDF từ × câu, chuẩn hóa L2 từng cột

→

4
NMF

k chủ đề → W: từ khóa, H: câu – chủ đề

→

5
Chọn câu

Phủ chủ đề: mỗi chủ đề lấy câu tiêu biểu nhất

→

6
Bản tóm tắt

Ghép theo thứ tự gốc

"Mô hình chủ đề là công cụ, tóm tắt là ứng dụng."

So sánh, hạn chế

	LSA (SVD)	LDA	NMF
Nền tảng	Đại số	Xác suất	**Đại số, không âm**
Diễn giải	Khó (có số âm)	Dễ	**Dễ (cộng tính)**
Độ phức tạp	Đơn giản	Phức tạp	**Đơn giản, nhanh hơn LDA**

Hạn chế

- Phải chọn k trước
- Nghiệm phụ thuộc khởi tạo ngẫu nhiên
- Tóm tắt trích xuất: có thể kém mạch lạc, mất ngữ cảnh, bỏ qua vị trí câu

Tiếp theo: Demo

1. **Mô phỏng NMF**
   Xem từng vòng cập nhật
2. **Tóm tắt văn bản**
   Tóm tắt một bài báo
3. **Thử nghiệm**
   Chạy trên tập dữ liệu thật